

Cas pràctic: Magatzem de dades per l'anàlisi de la conciliació laboral i familiar o work-life balance

PR2 - Explotació de dades

Nom: Marc Bracons Cucó

Aula 2



# Índex de continguts

### 1. Anàlisi de dades

# 2. Creació del model OLAP

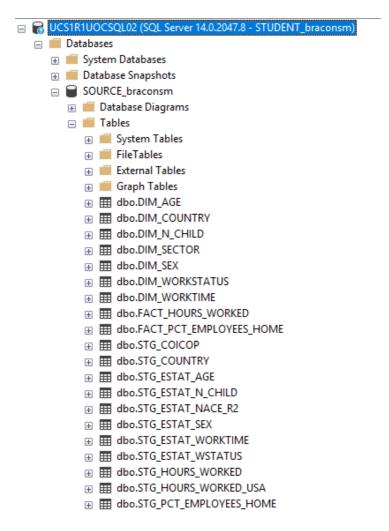
- 2.1. Creació del projecte
- 2.2. Vista de l'origen de dades
- 2.3. Creació i implementació dels cubs
  - 2.3.1. Dimensions generades
- 2.4. Jerarquies, dimensions i atributs
- 2.5. Processament i resolució d'errors

# 3. Explotació del model OLAP



### Anàlisi de dades

Per a la implementació del cub farem servir les dades amb les que hem anat treballant durant el cas pràctic. En concret amb les taules de dimensions i fets que hi ha al servidor UCS1R1UOCSQL02 a SOURCE\_braconsm.



Gràcies a aquestes taules podrem implementar un cub per a poder resoldre les següents consultes.

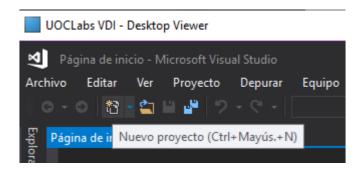
- 1) Percentatge de persones ocupades que van treballar des de casa durant l'any 2020. Els resultats es mostraran ordenats de menor a major.
- 2) Top 5 de sectors productius amb més hores treballades de mitjana durant 2021.
- 3) Evolució anual del percentatge de persones que treballen a casa a Espanya i Portugal des de l'any 2018 fins al 2022 (tots dos inclosos).
- 4) Percentatge d'hores treballades a casa segons el nombre de fills. El resultat es mostrarà arrodonit a un decimal.
- 5) Mitjana d'hores treballades als països de la UE durant l'any 2021, ordenats per regió i arrodonint el resultat a dos decimals. El resultat ha de mostrar la mitjana mensual.



# Creació del model OLAP

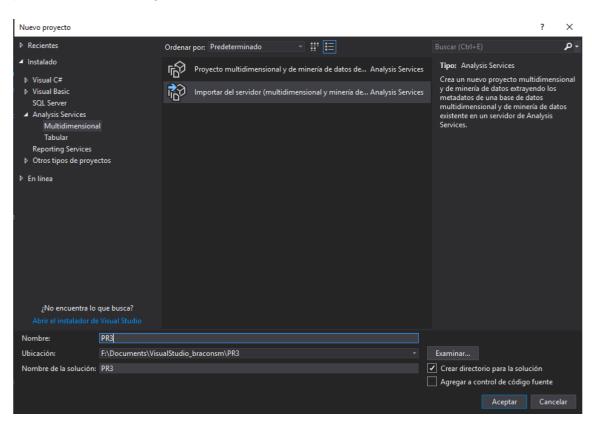
# Creació del projecte

Iniciem Visual Studio 2017 i seleccionem 'Nuevo proyecto'.



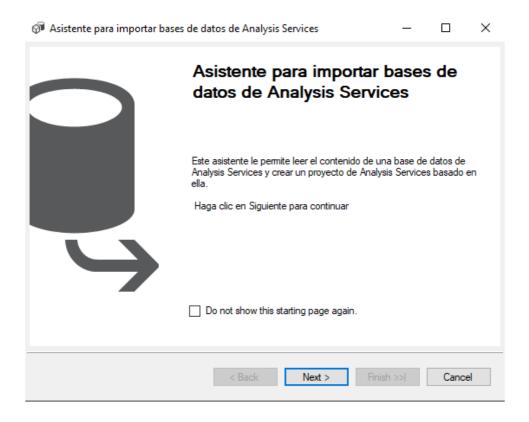
Crearem un projecte de tipus 'Proyecto multidimensional y de minería de datos', ja que ens permet crear cubs analítics i realitzar projectes de mineria de dades.

Seleccionem la opció 'Importar del servidor (multidimensional y minería de datos)', i li posem de nom PR3, guardem a F:\Documents\VisualStudio\_braconsm\PR3.

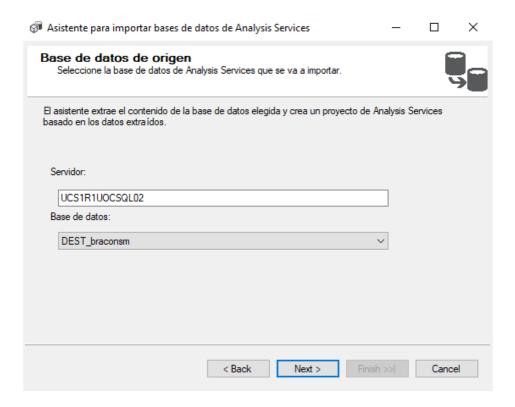


Al donar a acceptar salta el 'Asistente para importar bases de datos de Analysis Services'.



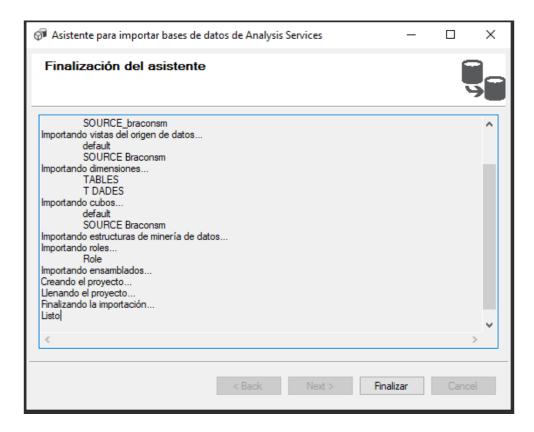


Introduïm les dades del servidor d'Analysys Services (UCS1R1UOCSQL02) i seleccionem DEST\_braconsm. Seleccionem 'Next' i importem la base de dades.

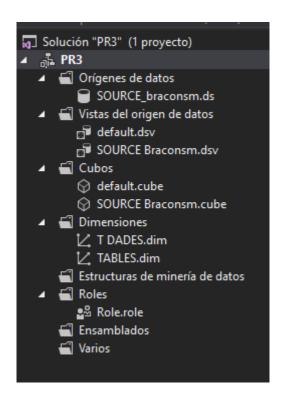




Seleccionem finalitzar i es tanca l'assistent.



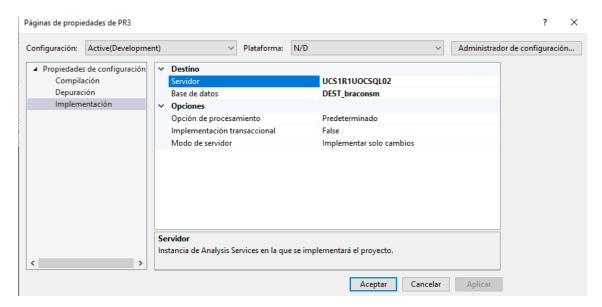
Podem veure que s'ha creat correctament. Tenim a origen de dades 'COURCE\_braconsm', també s'han creat una vista de dades, un cub, una taula de dimensions i un rol per defecte (aquests no els hem d'utilitzar ni esborrar durant la pràctica).





Finalment, anirem a les propietats del projecte i modificarem en la finestra 'Implementación' per a que 'Servidor' i 'Base de datos' tinguin els destins correctes.

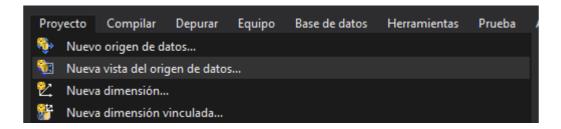
Servidor: UCS1R1UOCSQL02Base de datos: DEST\_braconsm





## Vista de l'origen de dades

En aquest punt crearem la vista de l'origen de dades. Per fer-ho farem clic a 'Nueva vista del origen de datos'.

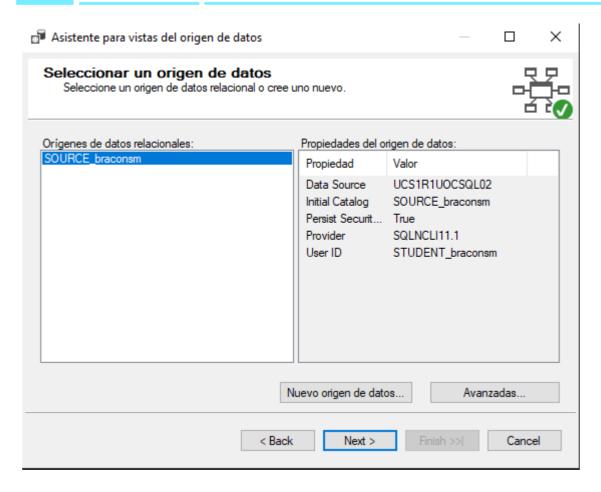


Al fer-ho s'obre l'assistent, on seleccionarem 'Next'.

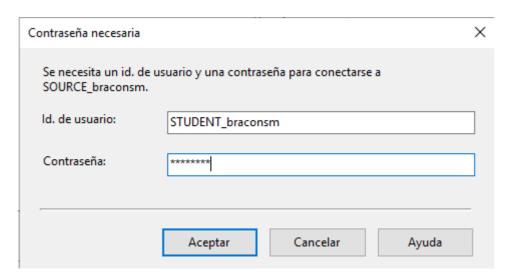


següent finestra podem veure l'origen de les dades relacionals (SOURCE\_braconsm) i les seves propietats així com Data Source (SOURCE\_braconsm), (UCS1R1UOCSQL02), Initial catalog User ID (STUDENT\_braconsm), entre d'altres.



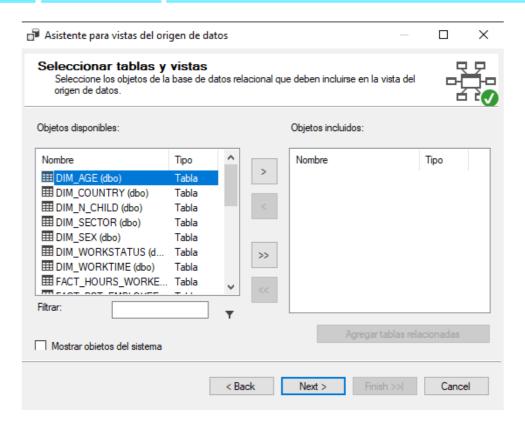


### Per fer la connexió es demana usuario i contrasenya

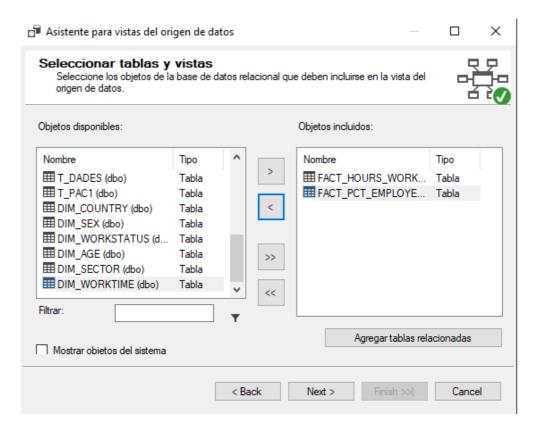


I a continuació veurem les taules que tenim a SOURCE\_braconsm. D'aquestes taules només en interessen les de fets i les de dimensions.



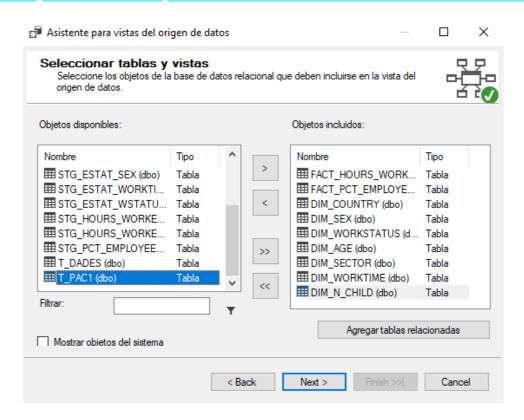


Primer agregarem les taules de fets FACT\_PCT\_HOURS\_WORKED i FACT\_HOURS\_WORKED.

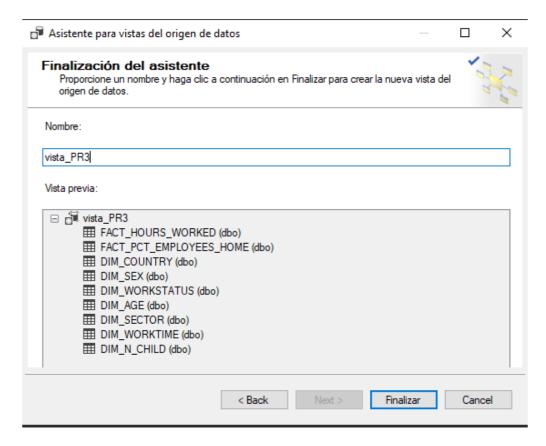


A continuació li donarem a 'Agregar tablas relacionades' a cada una de les taules de fets. Així quedarà la càrrega de taules abans de seleccionar 'Next'.



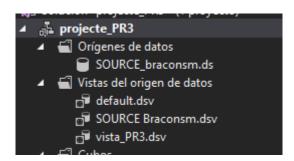


Li donarem un nom a la vista (vista\_PR3) i seleccionarem 'Finalizar'.

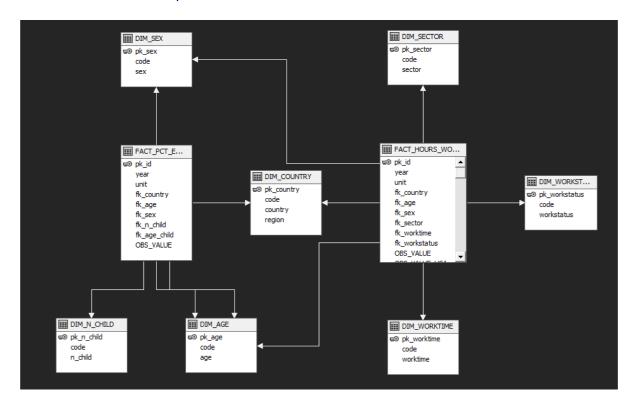


Podem veure que s'ha fet correctament, ja que a 'Vistas de origen de datos' ens surt 'vista PR3.dsv'





A més, si obrim la vista podem veure les taules i les relacions entre elles.

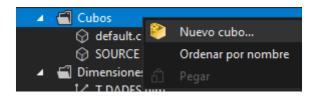


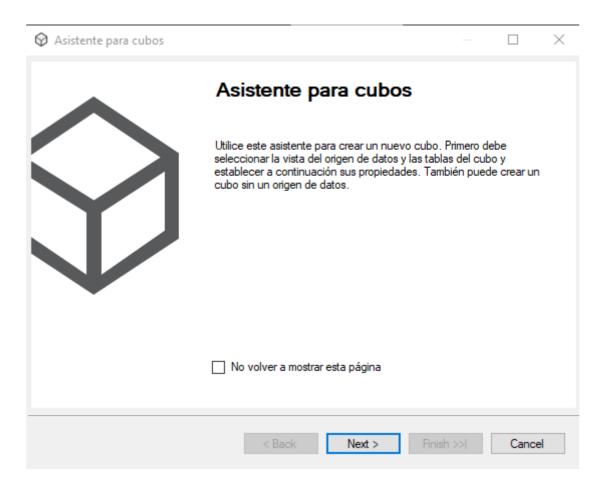


# Creació i implementació dels cubs

Després del pas anterior de creació de la vista, el pas següent és la creació dels cubs. Aquest pas ens permetrà realitzar les anàlisis OLAP per a l'explotació de les dades del magatzem de dades.

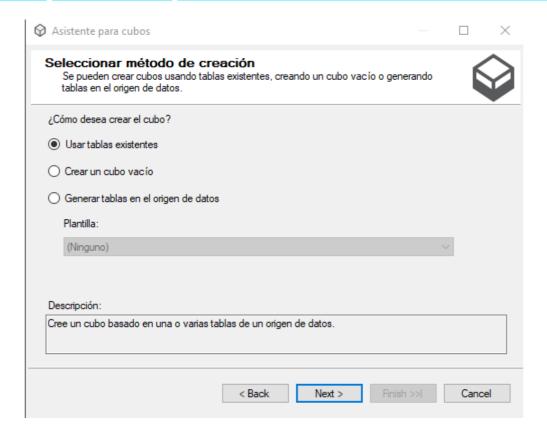
Crearem el cub des del menú contextual de cubs, seleccionem l'opció 'Nuevo cubo'



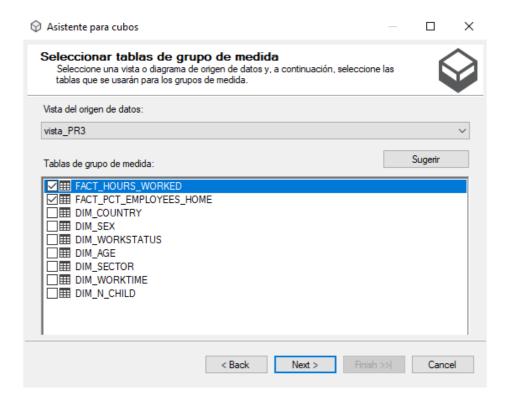


A l'assistent, indiquem que s'han de fer servir taules ja existents i triem la vista creada en el pas anterior per crear el cub.



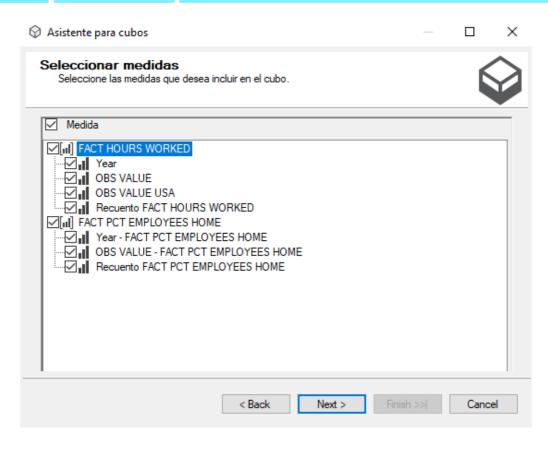


### Seleccionem 'vista\_PR3' i triem les taules de fets.

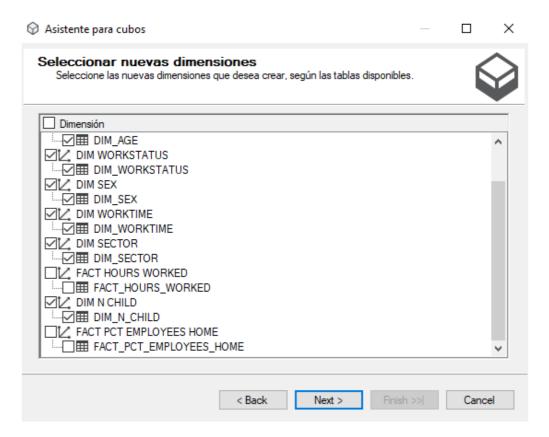


A continuació seleccionem les mètriques. Observem que a més de les definides, hi ha el recompte per a utilitzar-lo en la anàlisis i conèixer, per exemple, el nombre de mètriques realitzades al dia.



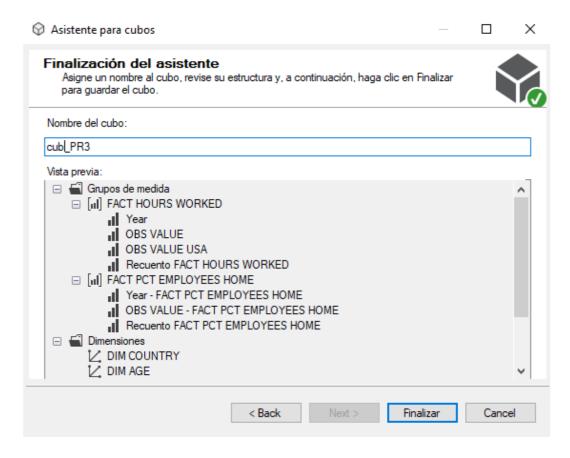


### A continuació seleccionem les dimensions.

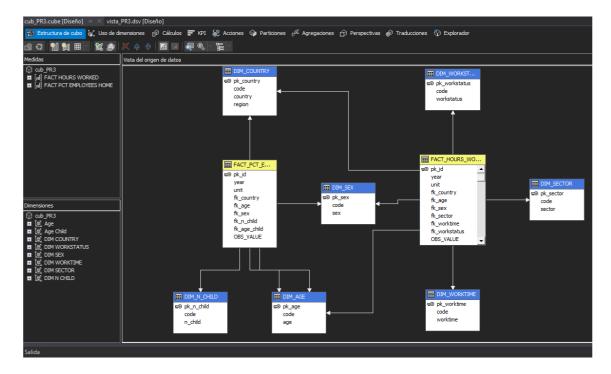


Abans de seleccionar 'Finalizar' podem veure un resum del cub que volem crear i li assignem el nom 'cub\_PR3'.



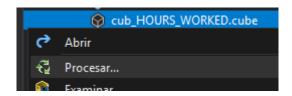


A la pantalla podem veure el model multidimensional del cub. També podem veure a la part esquerre les dimensions i les mesures que formen el model OLAP del cub.

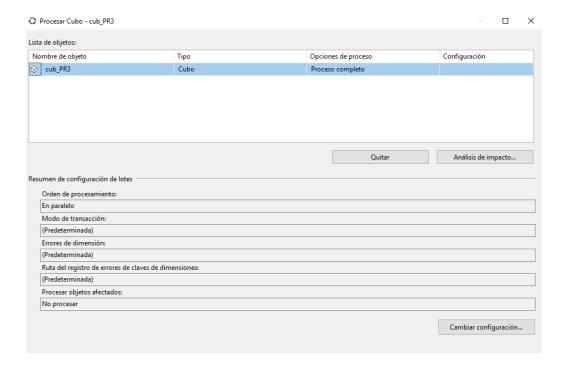


Per poder veure les dades del cub, hem d'implementar-lo al servidor d'SSAS. Per fer-ho hem de processar-lo.

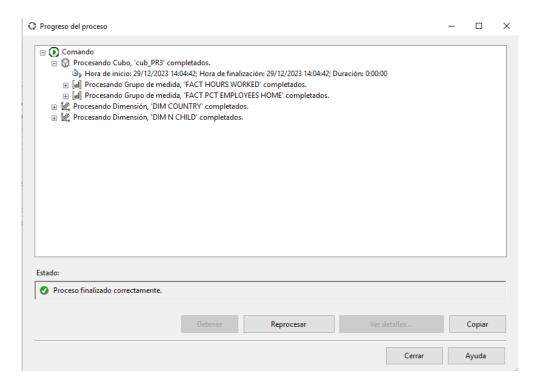




Un cop transcorregut el procés d'implementació apareix la finestra d'execució del cub. Seleccionarem 'Ejecutar'.

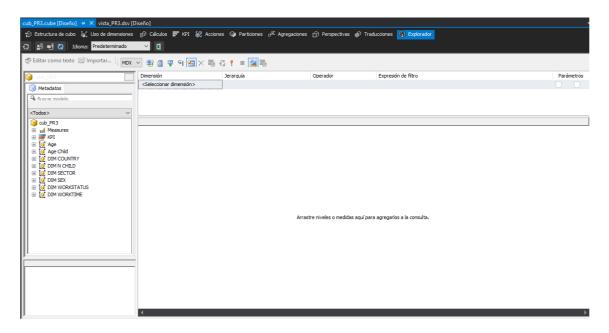


I podem veure que el procés ha finalitzat correctament.





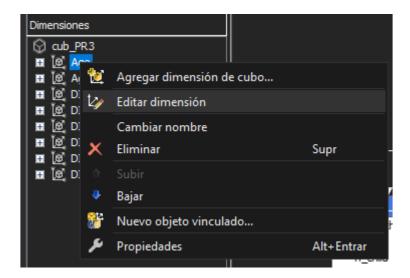
Si seleccionem la pestanya 'Explorador', ja podem navegar pel cub.



# Jerarquies i dimensions

Un cop definides totes les relacions del cub, treballarem amb les dimensions del projecte amb l'objectiu de definir els seus atributs i les seves jerarquies.

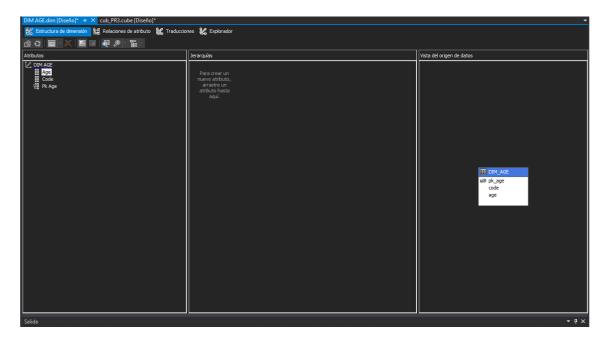
Per definir els atributs fem clic a 'Editar dimensión' en la dimensió que volem editar.



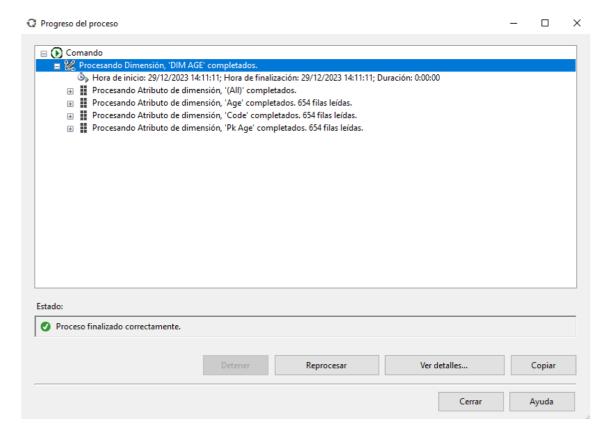


### **DIM AGE**

Per editar la dimensió, arrosseguem els atributs que volem des de la zona de 'Vista del origen de datos' fins a 'Atributos'. En aquest cas els hem arrossegat tots.



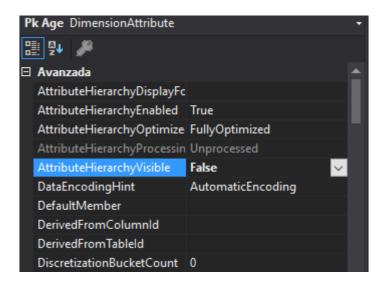
Un cop realitzats els canvis guardem i processem la dimensió.



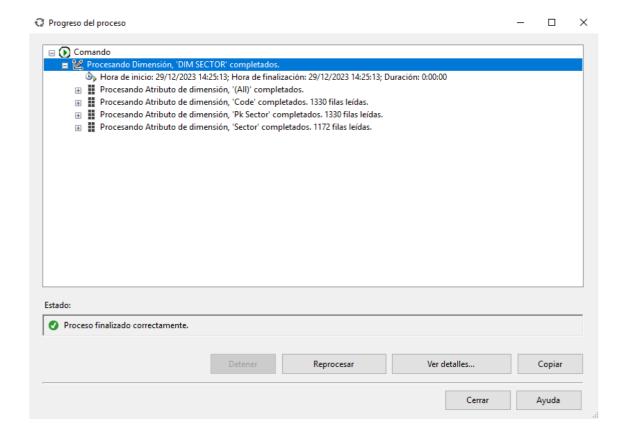
S'ha de tindre en compte que els analisten no haurien de poder treballar amb valors de tipus clau primària, atès que aquestes són d'ús intern per a la base de dades i, a



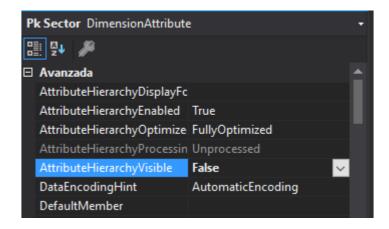
vegades, poden canviar entre càrrega i càrrega. A més, en tractar-se de claus subrogades, no ofereixen un valor que sigui fàcil d'entendre pels analistes. Per tot això, les ocultem seleccionant les propietats de l'atribut i canviant la propietat per 'AttributeHierarchyVisible'.



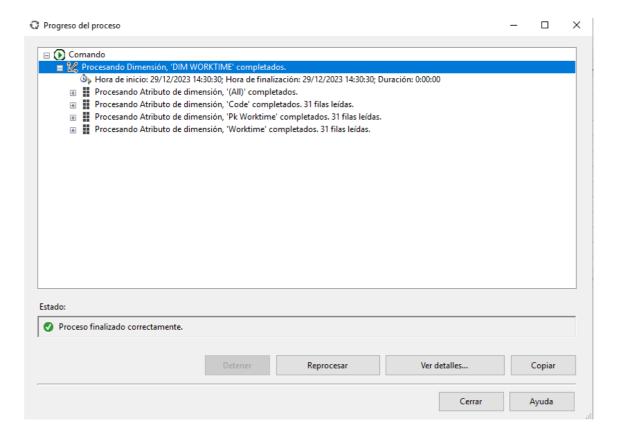
### **DIM SECTOR**



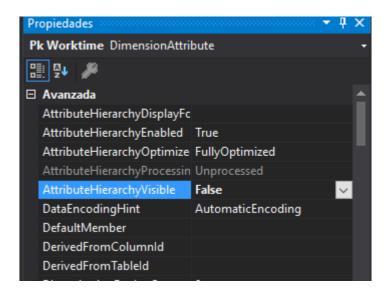




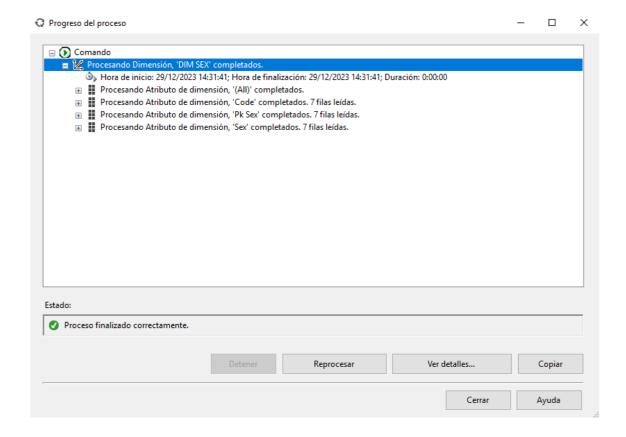
### **DIM WORKTIME**



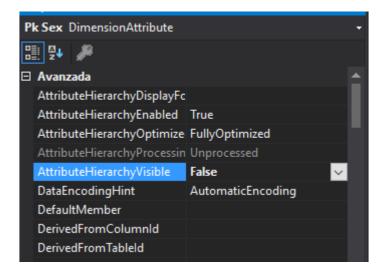




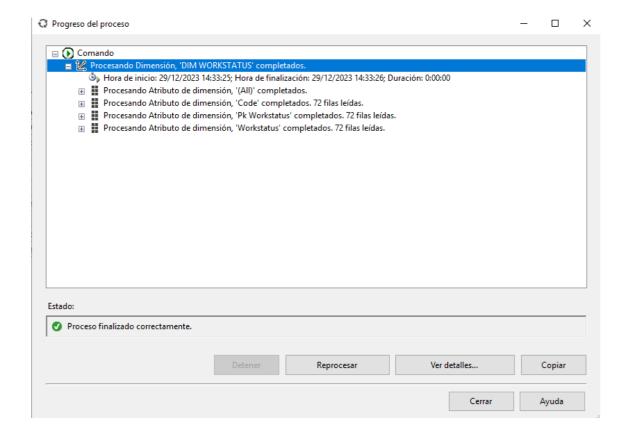
### **DIM SEX**



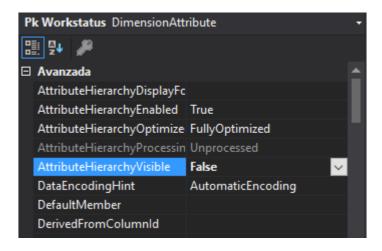




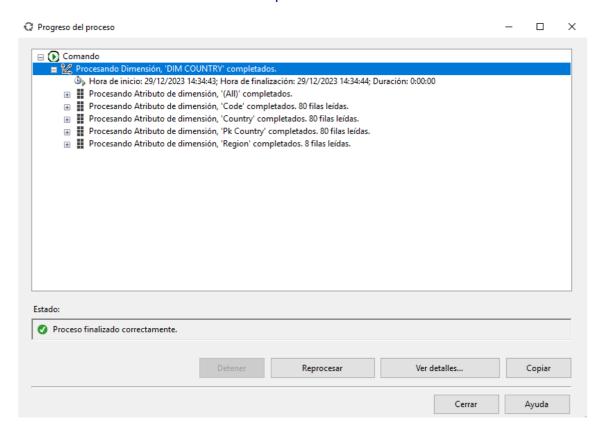
### **DIM WORKSTATUS**



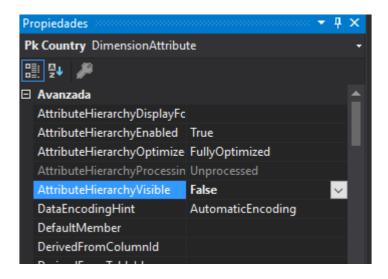




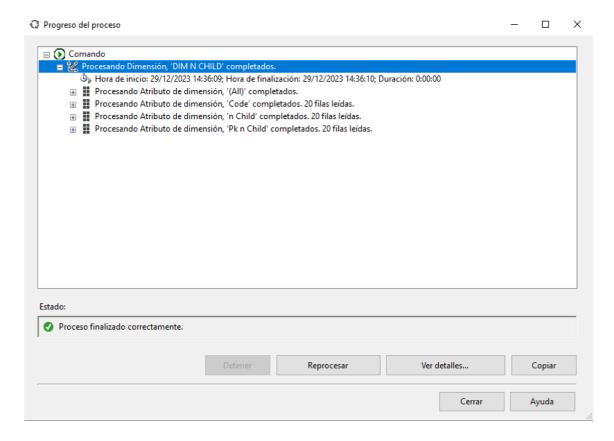
### **DIM COUNTRY**



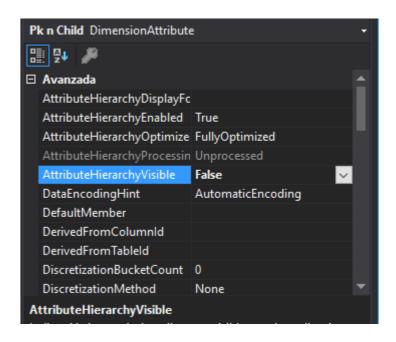




### **DIM N\_CHILD**

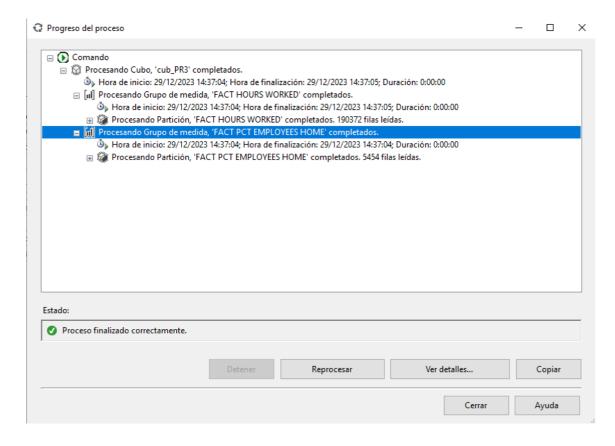






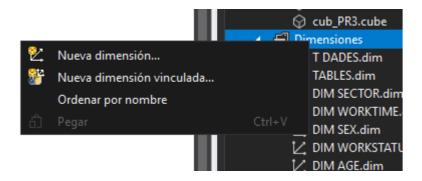
### Processament i resolució d'errors

Tornem a processar el cub per a tal que els canvis realitzats s'hi apliquin i a més, necessitarem crear una dimensió nova (DIM YEAR) per a poder fer les consultes que volem.

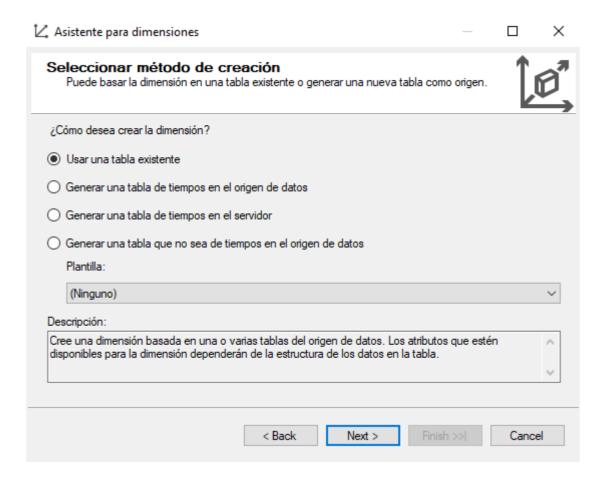




### Per a crear la nova dimensió farem clic a 'Nueva dimensión'

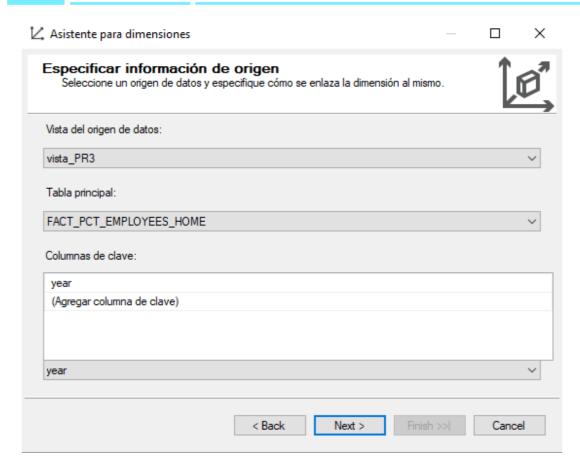


### Seleccionarem 'Usar una tabla existente' i li donarem a 'Next'

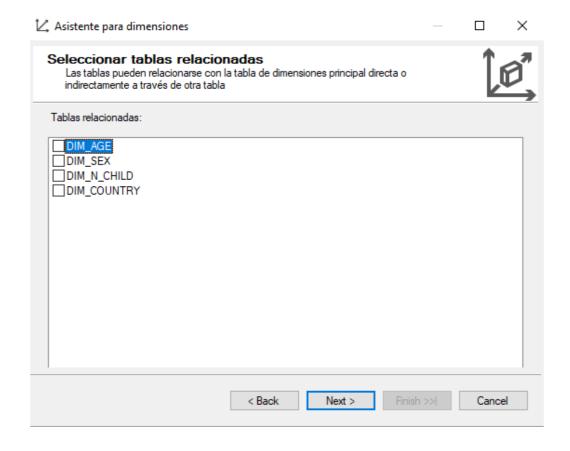


Seleccionem la vista amb la que estem treballant (vista\_PR3) i obtindrem els anys de una de les taules de fets.



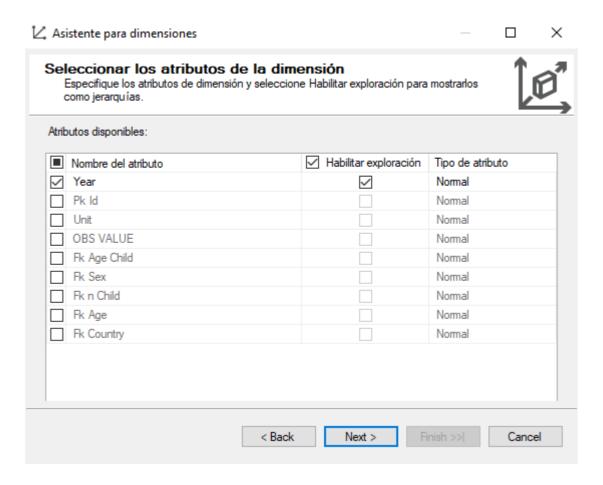


No volem que estigui relacionada amb altres taules així que desmarquem les altres taules de dimensions.

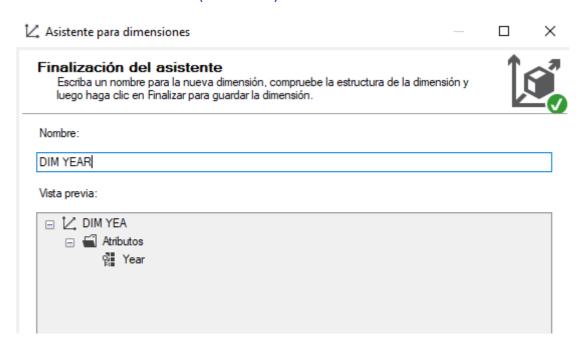




Deixem només l'atribut 'Year', ja que és l'únic que ens interessa.



Finalment li donem un nom (DIM YEAR).

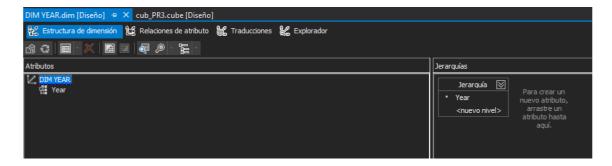


Podem veure que a la taula de dimensions hi ha aparegut la dimensió creada.





Al igual que amb les altres dimensions, la editarem per tal que 'Year' estigui a 'Atributos'.



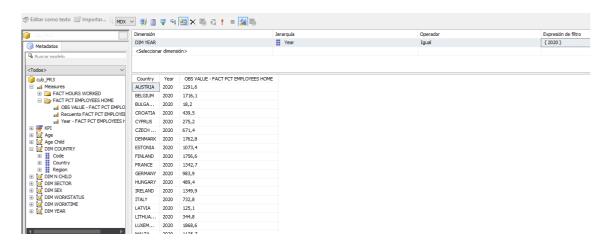
# Explotació del model OLAP

Ja ho tenim tot preparat per a poder veure la utilitat de un cub alhora de treure informació de bases de dades.

Percentatge de persones que treballen des de casa per país durant l'any 2020, ordenats per la dada corresponent de menor a major.

Aquesta anàlisi es pot fer utilitzant l'explorador de cubs que proporciona VS. Aquesta eina és una interfície gràfica senzilla que permet fer de manera ràpida consultes no gaire complexes i enriquir-les utilitzant el llenguatge MDX.

Des de l'àrea de metadades s'arrossegaran a l'àrea d'anàlisi l'atribut de jerarquia 'Country' de la dimensió DIM COUNTRY i la mesura OBS VALUE EH. També serà necessari incloure 'Year'='2020' en l'àrea de filtres.





Es pot apreciar que l'ordenació de les dades no és l'esperada. Interessa obtenir el resultat per OBS VALUE EH de menor a major. En aquest cas, s'utilitzarà el llenguatge MDX per enriquir aquesta consulta, en concret la funció ORDER. Per a això, és necessari accedir a l'editor de codi fent clic en l'eina Mode de Disseny.

### **SELECT**

NON EMPTY { [Measures].[OBS VALUE - FACT PCT EMPLOYEES HOME] } ON COLUMNS,

### NON EMPTY **ORDER**(

[DIM COUNTRY].[Country].[Country].ALLMEMBERS,

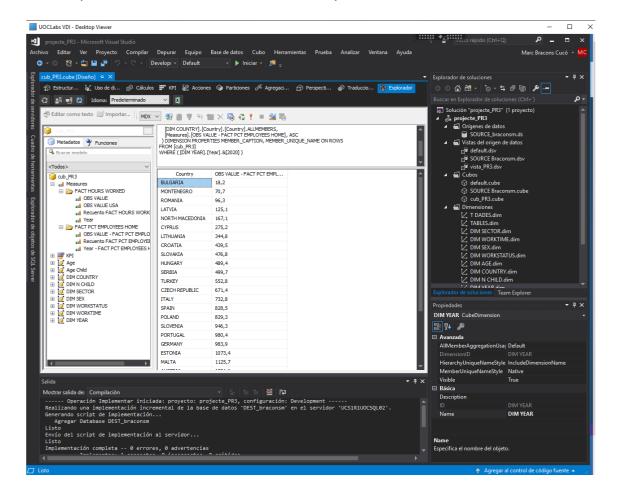
[Measures].[OBS VALUE - FACT PCT EMPLOYEES HOME], ASC

) DIMENSION PROPERTIES MEMBER\_CAPTION, MEMBER\_UNIQUE\_NAME ON ROWS

FROM [cub\_PR3]

WHERE ([DIM YEAR].[Year].&[2020])

I ara si que obtenim la informació en el format que volem





En els resultats es pot apreciar la relació de països ordenats de menor a major segons el percentatge de persones que treballen des de casa durant l'any 2020. Es pot observar que Bulgària és el país amb un menor percentatge de persones que treballen a casa, mentre que els Països Baixos és el país amb més valor.

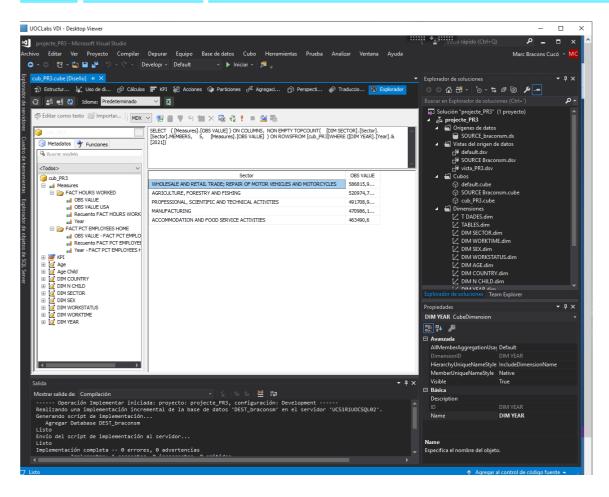
### Top 5 de sectors productius amb més hores treballades de mitjana durant 2021.

Per a treure aquesta informació del cub farem servir també una consulta MDX. Farem servir la funció TOPCOUNT per a seleccionar els 5 elements principals. A més eliminem els valors null.

# SELECT { [Measures].[OBS VALUE - FACT HOURS WORKED] } ON COLUMNS, TOPCOUNT( NON EMPTY [DIM SECTOR].[Sector].MEMBERS - [DIM SECTOR].[Sector].[(NULL)], 5, [Measures].[OBS VALUE - FACT HOURS WORKED] ) ON ROWS FROM [cub\_PR3]

WHERE ([DIM YEAR].[Year].&[2021])





Podem veure que el sector productiu amb més hores treballades és 'WHOLESALE AND RETAIL TRADE; REPAIR OF MOTOR VEHICLES AND MOTORCYCLES'. En segona posició hi ha 'AGRICULTURE, FORESTRY AND FISHING'. A continuació 'PROFESSIONAL, SCIENTIFIC AND TECHNICAL ACTIVITIES'. En quarta posició 'MANUFACTURING'. En última posició 'ACCOMODATION AND FOOD SERVICE ACTIVITIES'.

Evolució anual del percentatge de persones que treballen a casa a Espanya i Portugal des de l'any 2018 fins al 2022 (tots dos inclosos).

Fem servir [DIM YEAR].[Year].&[X] per a seleccionar les dades de l'any 'X'.

```
SELECT
{ [Measures].[OBS VALUE - FACT PCT EMPLOYEES HOME] } ON COLUMNS,
{
   [DIM YEAR].[Year].&[2018],
   [DIM YEAR].[Year].&[2019],
```



```
[DIM YEAR].[Year].&[2021],

[DIM YEAR].[Year].&[2022]

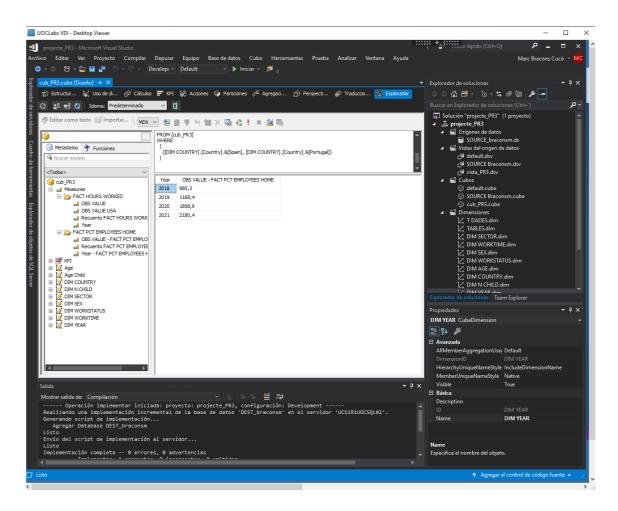
} ON ROWS

FROM [cub_PR3]

WHERE

(

{[DIM COUNTRY].[Country].&[Spain], [DIM COUNTRY].[Country].&[Portugal]}
)
```



Podem veure que la primera observació en el 2018 és de 980,3. A partir d'aquí cada any ha anat augmentant fins a arribar a 2180,4 en 2021.



Percentatge d'hores treballades a casa segons el nombre de fills. El resultat es mostrarà arrodonit a un decimal.

Definim la variable 'Total OBS VALUE' dins de 'Measures'. Li donem valor sumant tots els valors de 'OBS VALUE - FACT PCT EMPLOYEES HOME' per a cada valor de 'DIM N CHILD'.

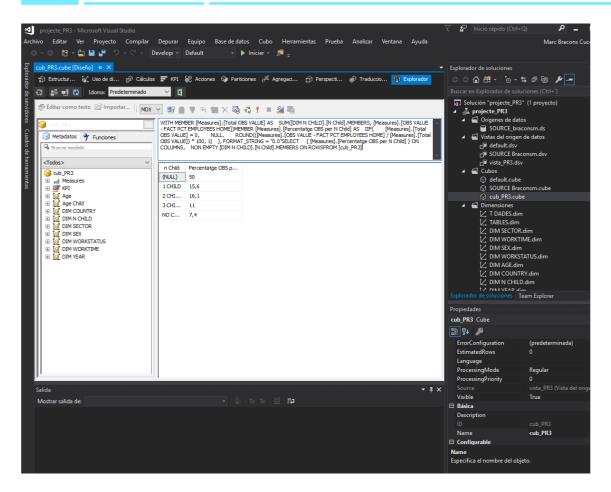
Fem el mateix amb 'Percentatge OBS per N Child', hem afegit que si la variable anterior es zero, llavors aquesta tindrà valor NULL per evitar dividir per zero.

Ferm servir FORMAT\_STRING = "0.0" per a tindre només un decimal.

A continuació fem la consulta i calculem els percentatges com valor observat dividit entre el total d'observacions i multiplicat per 100. Fem servir ROUND per mostrar només un decimal en la visualització de resultats.

```
WITH
MEMBER [Measures].[Total OBS VALUE] AS
  SUM([DIM N CHILD].[N Child].MEMBERS, [Measures].[OBS VALUE - FACT PCT
EMPLOYEES HOME])
MEMBER [Measures].[Percentatge OBS per N Child] AS
  IIF(
    [Measures].[Total OBS VALUE] = 0,
    NULL,
    ROUND(([Measures].[OBS VALUE - FACT PCT EMPLOYEES HOME] /
[Measures].[Total OBS VALUE]) * 100, 1)
  ), FORMAT STRING = "0.0"
SELECT
  { [Measures].[Percentatge OBS per N Child] } ON COLUMNS,
  NON EMPTY [DIM N CHILD].[N Child].MEMBERS ON ROWS
FROM [cub_PR3]
```





Podem veure que el 50% de les observacions estan en un valor (NULL). L'altre 50% es reparteix entre 1 fill (15,6%), 2 fills (16,1), 3 fills (11%) i no fills (7.4%).

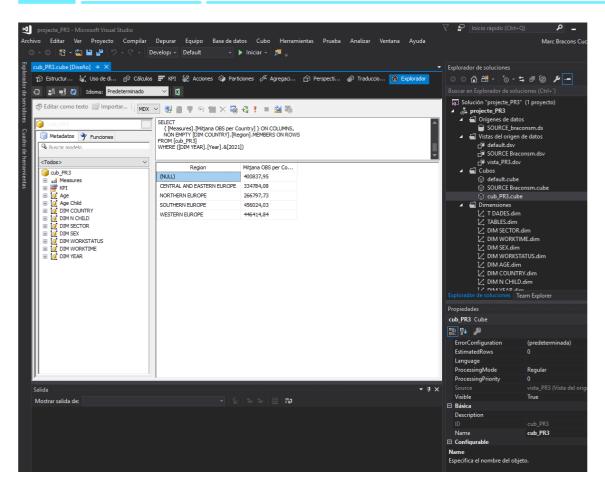
Mitjana d'hores treballades als països de la UE durant l'any 2021, ordenats per regió i arrodonint el resultat a dos decimals. El resultat ha de mostrar la mitjana mensual.

Guardem a 'Country Count' el nombre de països de cada regió. Guardem a 'OBS per Region' la suma del nombre d'observacions de tots els països de cada regió. I dividim el resultat entre el nombre de països que han sumat al total per a tindre una mitjana.



```
WITH
MEMBER [Measures].[Country Count] AS
  COUNT(
    FILTER([DIM COUNTRY].[Country].MEMBERS, NOT IsEmpty([Measures].[OBS
VALUE]))
 )
MEMBER [Measures].[OBS per Region] AS
  SUM(
    [DIM COUNTRY].[Country].MEMBERS,
    [Measures].[OBS VALUE]
 )
MEMBER [Measures].[Mitjana OBS per Country] AS
 IIF(
    [Measures].[Country Count] > 0,
    ROUND([Measures].[OBS per Region] / [Measures].[Country Count],2),
    NULL
  ), FORMAT_STRING = "0.00"
SELECT
 { [Measures].[Mitjana OBS per Country] } ON COLUMNS,
 NON EMPTY [DIM COUNTRY]. [Region]. MEMBERS ON ROWS
FROM [cub_PR3]
WHERE ([DIM YEAR].[Year].&[2021])
```



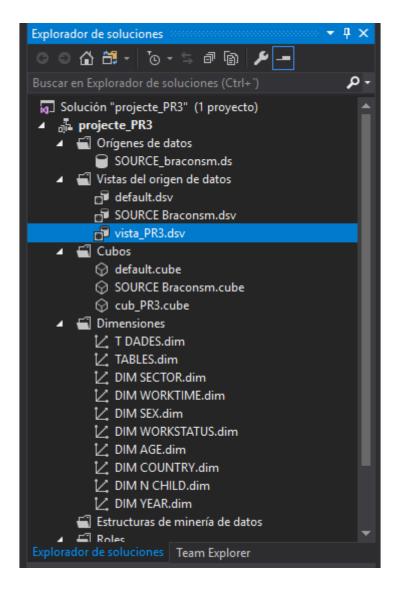


Podem veure que si ignorem el valors (NULL) la regió on de mitjana es treballa més hores és CENTRAL AND EASTERN EUROPE, seguit de NORTHERN EUROPE, SOUTHERN EUROPE i WESTERN EUROPE (en aquest ordre).



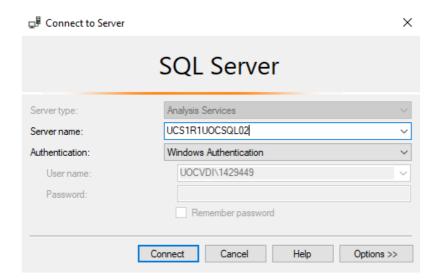
# **Imatges finals**

Com a part final de la pràctica mostrarem com ha quedat el 'Exploració de soluciones'. Hi podem veure la vista creada (vista\_PR3), així com el cub (cub\_PR3) i les dimensions utilitzades.





En el Microsoft SQL Server Management ens podem connectar al servidor.



I mirant al 'Object Explorer' hi podem veure que a DEST\_braconsm hi tenim el cub (cub\_PR3) i les dimensions utilitzades durant la pràctica.

